

Detecção de coluna vertebral utilizando DeepLabv3+

Aluno: Hector José Rodrigues Salgueiros (MATRÍCULA: 20219003176)

E-mail: hectorsalg@ufpi.edu.br; Período da Graduação: VII

Orientador: Antonio Oseas de Carvalho Filho

22 de julho de 2024

Resumo

Contexto: A detecção automática da coluna vertebral através de técnicas de aprendizado profundo surge como uma ferramenta promissora. O modelo DeepLabv3+, com sua alta capacidade de segmentação semântica, pode ser utilizado para identificar com precisão as vértebras cervicais em imagens de ressonância magnética. Além disso, o uso de aprendizado profundo permite que o modelo aprenda padrões complexos e sutis nas imagens, tornando-o capaz de generalizar para diferentes pacientes e variações anatômicas. Isso é fundamental para garantir resultados confiáveis e robustos em uma variedade de cenários clínicos.

Problema: A radiografia é um procedimento de diagnóstico por imagem amplamente empregado para avaliar a região vertebral. No entanto, a identificação manual das vértebras cervicais pode ser uma tarefa morosa e suscetível a erros humanos, dadas as nuances e complexidades da anatomia envolvida. Ademais, há o potencial risco de comprometimento de órgãos de risco durante tratamentos que envolvem exposição radiográfica prolongada, tornando essencial a adoção de técnicas precisas e seguras na condução desses procedimentos.

Proposta: Neste seguimento, propõe-se a construção de um modelo de aprendizado profundo, especificamente utilizando a arquitetura DeepLabv3+, para desenvolver uma metodologia para detecção automática da coluna vertebral em imagens de ressonância magnética. Com isso, diminuindo a necessidade de reavaliações de exames evitando danos aos órgãos de risco, e proporcionando ao especialistas monitorarem os resultados e conduzirem seus pacientes para melhor forma de tratamento.

Palavras-chaves: DeepLabv3+, Órgãos de risco, Radiografia, Radioterapia, Aprendizado Profundo, Coluna vertebral.

1 Introdução

Órgãos em risco, são órgãos próximos ao volume-alvo que podem ser afetados pela exposição à radiação durante o tratamento de radioterapia. Esses órgãos, apesar de saudáveis podem sofrer graves danos. No entanto, a segmentação manual é um processo que consome muito tempo e recursos (GIBBONS et al., 2023). Com isso, é necessária uma detecção automatizada para diminuir a carga de radiação nos órgãos em proximidade.

A detecção automática da coluna vertebral é um processo que utiliza técnicas de visão computacional e aprendizado profundo para identificar e segmentar as vértebras cervicais em imagens de ressonância magnética. Essa abordagem automatizada tem o potencial de agilizar e aprimorar o diagnóstico clínico, reduzindo o tempo e os erros associados à identificação manual dessas estruturas (WANG et al., 2023).

O uso do aprendizado profundo na detecção de vértebras cervicais permite que o modelo DeepLabv3+ analise e aprenda padrões complexos e sutis presentes nas imagens de ressonância magnética. Essa capacidade de análise é especialmente importante devido à variedade de variações anatômicas e diferentes pacientes (KUROKI; NAGAI, 2023). Ao treinar o modelo com um conjunto diversificado de dados, é desejado obter resultados mais precisos e generalizados na detecção das vértebras cervicais. Portanto, é essencial que o modelo seja treinado com uma ampla variedade de imagens para aprender e reconhecer essas variações. Assim, espera-se que supere a identificação manual da coluna vertebral com este modelo.

A identificação manual das vértebras cervicais em tratamentos de radioterapia apresenta desafios significativos. Esses desafios ocorrem desde contornos precisos para orientar as doses alvo de prescrição, ao tempo e recursos utilizados. Para superar esses desafios, será proposto um modelo de aprendizado profundo para automatizar este processo de identificação.

1.1 Objetivos Gerais e Específicos

Este trabalho tem como objetivo geral identificar e segmentar a coluna vertebral em imagens médicas, utilizando o modelo DeepLabv3+. Por fim, analisar os possíveis resultados mediante os testes.

Os objetivos específicos são:

1. Avaliar a viabilidade do uso de redes de detecção de objetos, como o DeepLabv3+, para a detecção da coluna vertebral.
2. Comparar o método desenvolvido com outros existentes na literatura.

2 Justificativa

A justificativa deste trabalho está fundamentada na necessidade de um método mais eficiente e preciso para a identificação da coluna vertebral em exames de imagem. Além disso, a detecção automática contribui para um diagnóstico mais rápido e seguro, auxiliando os profissionais de saúde no tratamento de doenças e lesões relacionadas à coluna vertebral. Conforme a identificação pelo médico será realizada mais rapidamente. A identificação automatizada diminui as doses de radiação nos órgãos em risco, devido a aceleração no processo de tratamento.

A utilidade e eficácia do modelo DeepLabv3+ é notável, uma vez que sua precisão e confiabilidade estão comprovadas por meio de estudos e análises em tumores cerebrais (Yaqub et al., 2023), assim apresentado na Figura 1, resultados adquiridos após a utilização do modelo incentivam a tentativa de análise em outras áreas da saúde, em nosso estudo, a detecção da coluna vertebral. Diante disso, a utilização desse modelo pode ser um avanço no campo da radiologia e contribuir para a evolução dos métodos de diagnóstico e tratamento de doenças relacionadas à coluna vertebral.

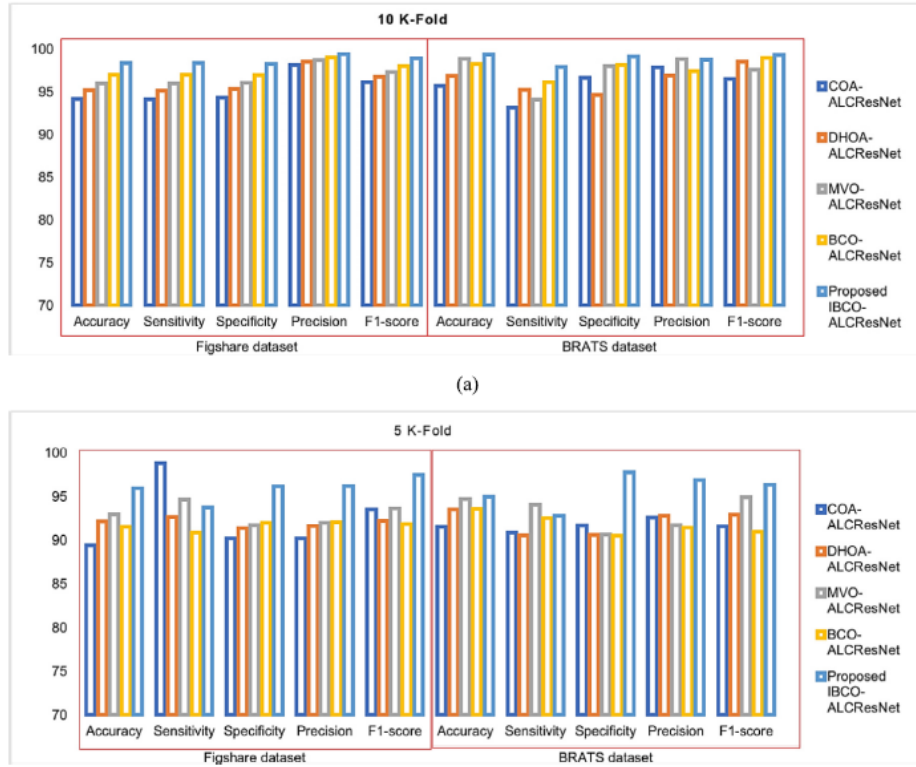


Figura 1 – Dados do estudo em tumores cerebrais.

A coluna vertebral possui inúmeros problemas que podem ser gerados com traumas ou lesões (ZANZA et al., 2023), além das anomalias. Devido esses problemas, existem diversos motivos para se realizar uma ressonância magnética, ou realizar um tratamento com sessões ao decorrer do tempo. Diminuir essas sessões irá amortecer as doses e os danos gerados nos órgãos em risco.

3 Referencial Teórico

Essa seção irá abranger alguns conceitos que são necessários para o entendimento deste pré-projeto, serão abordados aqui, os conceitos de: aprendizado de máquina, aprendizado profundo, e redes de detecção de objetos para a detecção da coluna vertebral para auxiliar no tratamento de quimio e radio, devido órgãos de risco serem afetados durante o tratamento, com a finalidade de mostrar a importância das segmentação nesses órgãos.

3.1 Aprendizado de Máquina

A aprendizagem de máquina é uma categoria da inteligência artificial que engloba diversos algoritmos computacionais utilizados para extrair informações de conjuntos de dados. A partir de um conjunto de treinamento, esses algoritmos procuram identificar padrões que relacionam entradas a saídas, possibilitando fazer previsões com base nesses padrões (ALPAYDIN, 2021). O objetivo da aprendizagem de máquina é desenvolver programas que aprimorem seu desempenho por meio de exemplos, os quais podem ser dados como imagens, textos, áudio, entre outros tipos de informação (ZHOU, 2021).

Dependendo da maneira como esses dados são apresentados, diferentes abordagens podem ser aplicadas, incluindo aprendizagem supervisionada, não supervisionada e por reforço.

Na aprendizagem supervisionada, os modelos são treinados com dados rotulados, ou seja, dados que já têm uma resposta conhecida. Aqui, o algoritmo é alimentado com pares de entrada e saída conhecidos, geralmente representados como vetores. Para cada saída, o algoritmo atribui um rótulo e tenta aprender a relação entre as características da entrada e a saída, permitindo fazer previsões sobre o rótulo da saída com base na entrada fornecida (ALPAYDIN, 2021).

Na aprendizagem não supervisionada, não há rótulos nos dados de saída, ou seja, não se sabe o resultado desejado. O algoritmo analisa um grande volume de dados em busca de padrões e similaridades entre eles, possibilitando identificar grupos de itens semelhantes ou a similaridade de novos itens com grupos já existentes (ALPAYDIN, 2021).

No aprendizado por reforço, um agente interage com um ambiente realizando ações e recebendo recompensas ou penalidades com base nos resultados dessas ações. O objetivo do algoritmo é maximizar a recompensa recebida. Esses sistemas incluem três componentes principais: o agente (o programa sendo treinado), o ambiente e a interação entre esses dois, onde o agente observa, interage e modifica o ambiente ao longo do tempo (ALPAYDIN, 2021).

3.2 Aprendizado profundo

O aprendizado profundo é uma abordagem que permite explorar múltiplas camadas de processamento de informações não-lineares utilizando técnicas avançadas de aprendizado de máquina (JANIESCH; ZSCHECH; HEINRICH, 2021). Com essa técnica, os algoritmos conseguem aprender diferentes níveis de representação e abstração dos dados, dando-lhes significado.

Os métodos de aprendizado profundo procuram identificar modelos (regras, parâmetros, padrões) usando conjuntos de dados (exemplos) e métodos que orientam o aprendizado desses modelos a partir desses exemplos. O objetivo é descobrir padrões complexos em várias formas de entrada (como imagens, textos, áudios, etc.) e relacionar a saída desses exemplos com os padrões presentes nos conjuntos de entrada. Ao final do processo de aprendizado, obtemos uma função capaz de transformar dados brutos de entrada em uma representação adequada para resolver o problema em questão (CHOUDHARY et al., 2022).

O aprendizado profundo tem sido aplicado em diversas áreas, principalmente em Visão Computacional, como Processamento de Imagens e Computação Gráfica. Técnicas como Redes Neurais Convolucionais (CNNs), Redes de Crenças Profundas (Deep Belief Networks), Máquinas Restritas de Boltzmann (Restricted Boltzmann Machines) e Autoencoders têm surgido como base para os métodos de ponta em várias aplicações (DONG; WANG; ABBAS, 2021).

3.3 Redes de detecção de objetos

Em visão computacional, a detecção de objetos é um termo que define um conjunto de tarefas que envolvem a identificação e localização de objetos em imagens ou vídeos. Abordagens como R-CNN (Redes Neurais Convolucionais baseadas em Região), usam métodos de proposta de região para primeiro gerar possíveis caixas delimitadoras em uma imagem e, em seguida, executar um classificador nessas caixas propostas (XIE et al., 2021). Depois dessa classificação, o pós-processamento é usado para refinar as caixas

delimitadoras, eliminar detecções duplicadas e pontuar novamente as caixas baseadas em outros objetos na cena.

O modelo DeepLabv3+, criado pela Google, reformula a detecção de objetos ao transformá-la em um único problema de regressão, mapeando diretamente dos pixels da imagem para as coordenadas da caixa delimitadora e as probabilidades de classe. Usando este modelo, permite identificar e localizar objetos em imagens com alta precisão, mesmo em cenários complexos com objetos sobrepostos ou parcialmente obscurecidos (PENG et al., 2020).

Conforme dito em Hioki et al. (2021), DeepLabv3+ estende DeepLabv3 adicionando uma estrutura de codificador-decodificador. O módulo codificador processa informações contextuais multiescala aplicando convolução dilatada em múltiplas escalas, enquanto o módulo decodificador refina os resultados da segmentação ao longo dos limites do objeto. Com a convolução dilatada, à medida que avançamos na rede, podemos manter a passada constante, mas com um campo de visão maior sem aumentar o número de parâmetros ou a quantidade de computação. Além disso, permite mapas de recursos de saída maiores, o que é útil para segmentação semântica.

O DeepLabv3+ também incorpora uma técnica chamada Pyramid Scene Parsing (PSP), que agrega informações contextuais globais para melhorar a precisão da segmentação. A PSP divide a imagem em várias sub-regiões e realiza a média de agrupamento em cada uma delas. Isso permite que o modelo capture informações em diferentes escalas e melhore a precisão da segmentação, especialmente em torno dos limites dos objetos. Além disso, o DeepLabv3+ utiliza uma função de perda de entropia cruzada ponderada para treinamento, que dá mais importância aos pixels que pertencem a classes minoritárias, ajudando assim a melhorar o desempenho em conjuntos de dados desequilibrados. Essas características fazem do DeepLabv3+ uma ferramenta poderosa para tarefas de segmentação (ZHU et al., 2023).

4 Trabalhos Relacionados

A literatura apresenta uma série de trabalhos com a utilização do modelo DeepLabv3+. Esta seção mostra trabalhos que utilizaram diferentes abordagens e técnicas para realizar a detecção da coluna vertebral.

O artigo Choudhury et al. (2019) se concentra na utilização da rede DeepLabv3+ para segmentação de tumores cerebrais, atingindo coeficientes médios de Dice de 0,7086, 0,7897 e 0,8755 para o aumento do tumor, núcleo do tumor e regiões do tumor inteiro, respectivamente. O treinamento envolve 150.000 iterações com verificações de desempenho a cada 5.000 iterações, obtendo melhores resultados para diferentes regiões tumorais em diferentes contagens de iterações. Os classificadores finais são combinados com base na relação entre as regiões tumorais, garantindo que os pixels sejam atribuídos corretamente a cada região, com o núcleo do tumor sendo um subconjunto do tumor inteiro e o tumor potenciador sendo um subconjunto do núcleo tumoral. O artigo discute a importância de considerar fatias vizinhas para a precisão da segmentação e aborda o desequilíbrio de classes concentrando-se em fatias com tumores durante o treinamento.

O artigo Wang e Liu (2021) propõe um modelo automático de segmentação do câncer gástrico baseado na rede neural DeepLabv3+. O modelo alcançou uma sensibilidade de 91,45%, especificidade de 92,31%, precisão de 95,76% e coeficiente de Dice de 91,66%. A pesquisa se concentra em melhorar o reconhecimento e a segmentação de imagens de fatias

patológicas do câncer gástrico. O modelo de segmentação proposto complementa essas ferramentas de diagnóstico, fornecendo informações detalhadas sobre as regiões cancerosas nas imagens gástricas. Ao comparar o modelo DeepLabv3+ com o SegNet, a pesquisa destaca o desempenho superior da abordagem proposta na análise de imagens de câncer gástrico. O foco do estudo em aprimorar o reconhecimento e a segmentação de imagens do câncer gástrico ressalta a importância de aproveitar técnicas avançadas de aprendizado profundo em imagens médicas.

No artigo [Mushtaq et al. \(2022\)](#) emprega o conjunto de dados composto da coluna lombar, que pode ser acessado abertamente nos dados de Mendeley. Várias técnicas de aumento são aplicadas ao conjunto de dados para aumentar a variabilidade e reduzir o sobreajuste, incluindo adição de ruído, inversão de imagem, rotação de 90 graus, corte de imagem e distorção de imagem. Para aprimorar a generalização e o desempenho do modelo, o conjunto de dados passa por técnicas de aumento, como adição de ruído, inversão de imagem, rotação, corte e distorção. a pesquisa visa fornecer métodos automatizados para os médicos classificarem a gravidade da doença com confiança, abordando a variabilidade nos diagnósticos manuais e auxiliando na análise das deformidades da coluna lombar.

O artigo [Shoushtari, Sina e Dehkordi \(2022\)](#) desenvolveu um algoritmo de rede neural profunda, Deep-Net, usando a arquitetura Deeplabv3+ com pesos Resnet18 pré-treinados para segmentação de tumores de glioblastoma em imagens de ressonância magnética. O Deep-Net otimizado alcançou uma precisão global de 97,53% e uma função de perda de 0,14, com alta sensibilidade na delimitação do tumor aprimorado. O estudo se concentrou na otimização dos hiperparâmetros do modelo, cruciais para modelos de aprendizado profundo, para aprimorar o comportamento do processo de treinamento e o desempenho do modelo. O foco do estudo na otimização dos hiperparâmetros da rede e na utilização da função de perda de entropia cruzada guiou o processo de aprendizagem, levando à segmentação bem-sucedida de diferentes sub-regiões tumorais em imagens de ressonância magnética

O artigo [Qadri et al. \(2023\)](#) se concentra na segmentação vertebral automática por TC usando uma abordagem de aprendizado profundo baseada em patches, com o objetivo de aprimorar as aplicações clínicas. O papel crucial da coluna vertebral na mobilidade, transferência de peso e proteção da medula espinhal ressalta a importância da segmentação vertebral precisa para diagnosticar anormalidades da coluna vertebral e planejar intervenções cirúrgicas. Métricas de avaliação como precisão, recordação, exatidão, pontuação F, interseção sobre união (IoU) e coeficiente de Dice são usadas para avaliar o desempenho dos métodos de segmentação vertebral, garantindo sua eficácia em aplicações clínicas. O uso de técnicas de aprendizado profundo, especificamente SSAE, permite o aprendizado de recursos de alto nível apenas a partir de intensidades de pixels, permitindo que o modelo reconheça características distintas em manchas de imagem e as classifique como vértebras ou não vértebras.

A Tabela 1 apresenta uma comparação desses trabalhos, avaliando-os com base nos seguintes critérios: foco principal da solução, a utilização do DeepLabv3+ e a segmentação na coluna vertebral, tamanho da amostra utilizada e os resultados alcançados. Esses critérios são fundamentais para entender como outras soluções têm sido desenvolvidas e quais lacunas ainda existem.

Tabela 1 – Trabalhos relacionados

Trabalho	Objetivo	Utilização do DeepLabv3+	Segmentação da Coluna Vertebral	Tamanho da Amostra Utilizada	Resultados Alcançados (Dice)
Choudhury et al. (2019)	Segmentação de Tumores Cerebrais	Sim	Não	351	87.54%
Wang e Liu (2021)	Reconhecimento e Segmentação com Imagens Médicas	Sim	Não	1340	91.66%
Mushtaq et al. (2022)	Localização e Segmentação da Coluna	Não	Sim	Não Informado	74.5%
Shoushtari, Sina e Dehkordi (2022)	Segmentação automática do Glioblastoma	Sim	Não	586	97.53%
Qadri et al. (2023)	Segmentação Automática da Coluna	Não	Sim	Não Informado	90.2%
Este pré-projeto	Aplicação do Modelo DeepLabv3+ para a Segmentação da Coluna Vertebral em Imagens Médicas	Sim	Sim		

5 Esboço da Proposta

O principal problema abordado neste pré-projeto será a detecção da coluna vertebral. Este estudo é importante devido às desvantagens apresentadas em relação à detecção feita de forma manual, sendo bastante repetitiva para o profissional responsável e demandando muito tempo e esforço visual. Esse processo ainda é passível de erros e falhas, o que pode comprometer os órgãos de risco. Por isso, existe a necessidade do uso de técnicas computacionais acessíveis com uma taxa de erro aceitável e baixo custo computacional. A proposta deste estudo é uma metodologia computacional de detecção automática da coluna vertebral utilizando aprendizado profundo, de maneira mais específica, utilizando redes de detecção de objetos, como o DeepLabv3+, que assim, irá auxiliar os profissionais responsáveis pela detecção.

Para solucionar o problema da detecção da coluna vertebral, será necessário realizar uma busca de imagens em bases públicas contendo imagens de coluna vertebral. Com as imagens coletadas, será possível montar uma base privada que servirá de entrada para os modelos de detecção de objetos. Dessa forma, eles poderão identificar, ao final, a região da coluna vertebral. Os modelos escolhidos farão a detecção da região da coluna vertebral com base nas áreas detectadas. Como já mostrado anteriormente, a rede de detecção de

objetos a ser utilizada será o DeepLabv3+.

Com o modelo devidamente treinado, o próximo passo é fazer a estimação da detecção da coluna vertebral, e esta etapa será muito importante para o resultado final da detecção, pois as regiões detectadas podem conter anomalias, logo, isso deve ser tratado com cuidado, tendo em vista que a rede pode, por exemplo, não detectar a coluna, outro caso, é a detecção da coluna vertebral numa região onde não há coluna.

Por fim, será feito a avaliação da qualidade e acurácia da detecção da coluna no treinamento do modelo. Abaixo são mostradas as principais métricas para avaliação de modelos de detecção de objetos ([WANGENHEIM, 2022](#)).

- Verdadeiro Positivo (VP) - representa uma classificação correta da classe Positiva. Um Verdadeiro Positivo ocorre quando o teste indica a presença de uma doença e, de fato, o indivíduo está acometido por ela. Essa situação representa o ideal em termos diagnósticos, pois confirma a presença da doença e permite o direcionamento adequado do tratamento.
- Falso Positivo (FP) - representa uma classificação incorreta para a classe Positiva, neste caso o resultado real era para ser da classe Negativa. Um Falso Positivo surge quando o teste indica a presença de uma doença, mas, na realidade, o indivíduo está saudável. Essa situação pode gerar procedimentos médicos desnecessários, além de comprometer a credibilidade do teste.
- Verdadeiro Negativo (VN) - representa uma classificação correta da classe Negativa. Um Verdadeiro Negativo ocorre quando o teste indica a ausência de uma doença e, de fato, o indivíduo está saudável.
- Falso Negativo (FN) - representa uma classificação incorreta para a classe Negativa, neste caso o resultado real era para ser da classe Positiva. Um Falso Negativo ocorre quando o teste indica que o indivíduo não possui uma doença, mas, na verdade, ele está realmente doente. Essa situação é alarmante, pois pode resultar em atrasos no diagnóstico e tratamento adequados, o que tem o potencial de afetar negativamente a saúde do indivíduo.

A acurácia fornece a visão geral do desempenho do modelo, mostrando o quão bem feitas foram suas classificações, é expressa pela seguinte fórmula:

$$acurácia = \frac{VP + VN}{VP + VN + FP + FN}$$

A precisão mede as classificações da classe positiva e diz, de modo geral, quantas estão corretas, é expressa pela seguinte fórmula:

$$precisão = \frac{VP}{VP + FP}$$

O recall toma todas as classes positivas e qualifica quantas estão corretas, é expressa pela seguinte fórmula:

$$recall = \frac{VP}{VP + FN}$$

E por fim, o F1 score realiza a média harmônica entre a precisão e o recall, é expressa pela seguinte fórmula:

$$F1score = 2 \cdot \frac{precisão \cdot recall}{precisão + recall}$$

6 Metodologia e Cronograma

Nesta seção será abordada a metodologia para o processo de detecção automática da coluna vertebral, utilizando a rede DeepLabv3+. A metodologia utilizada consiste nas seguintes etapas: levantamento bibliográfico, definição das métricas de avaliação, aquisição das imagens, treinamento e avaliação do modelo de detecção, análise dos resultados. A Figura 2 apresenta um modelo baseado em UML (Unified Modeling Language) que mostra a metodologia descrita.

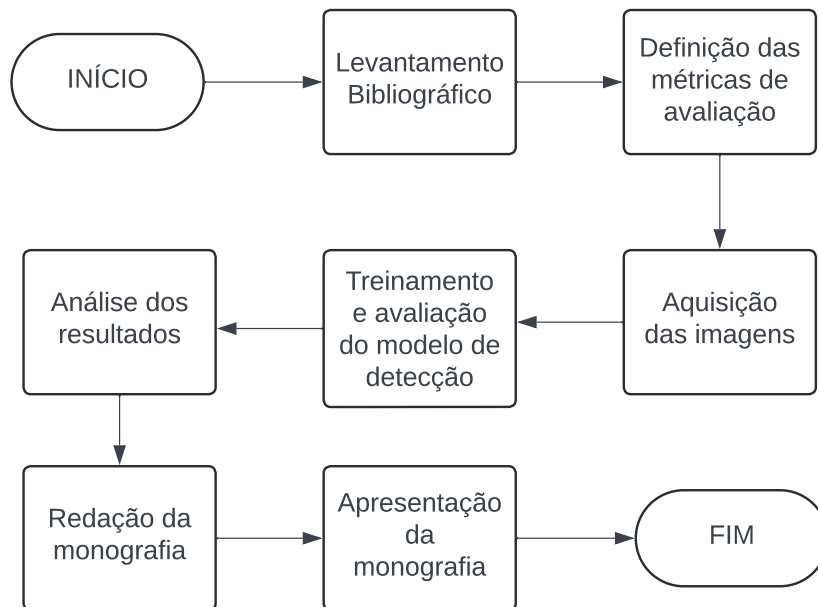


Figura 2 – Etapas da metodologia do projeto.

Levantamento bibliográfico: A etapa de levantamento bibliográfico será a inicial, pois nela serão buscados trabalhos relacionados, se existem técnicas já aplicadas de detecção de objetos e por último, adquirir conhecimento técnico e uma melhor compreensão sobre o problema abordado.

Definição das métricas de avaliação: As métricas aqui definidas para avaliar a qualidade das detecções serão: acurácia, precisão, recall e F1 score.

Aquisição das imagens: Para o treinamento e avaliação dos métodos propostos é necessário uma base de imagens, portanto será feito uma busca em bases públicas já aplicadas a outros trabalhos, e desenvolver uma base própria em parceria com outros laboratórios.

Treinamento e avaliação dos modelos de detecção: Será avaliado o modelo de detecção de objetos DeepLabv3+. Para seu treinamento e avaliação será utilizada, respectivamente, a base de imagens desenvolvida, e as métricas mencionadas anteriormente.

Análise dos resultados: A qualidade das detecções será avaliada com base nas métricas já definidas. Os resultados obtidos pelo modelo será comparado e com trabalhos existentes que utilizaram detecção de objetos.

E Por fim, o cronograma a ser seguido no desenvolvimento deste projeto é apresentado na Tabela 2:

Tabela 2 – Cronograma do Projeto

Atividade	Mês 1-2	Mês 3-6	Mês 7-8	Mês 9-10	Mês 11-12
Levantamento Bibliográfico	X				
Definição de métricas de avaliação	X				
Aquisição de imagens	X	X			
Treinamento e avaliação do modelo de detecção		X	X		
Análise dos resultados			X		
Redação da monografia			X	X	
Apresentação da monografia					X

Referências

ALPAYDIN, E. *Machine learning*. [S.l.]: MIT press, 2021. Citado 2 vezes nas páginas 3 e 4.

CHOUDHARY, K. et al. Recent advances and applications of deep learning methods in materials science. *npj Computational Materials*, Nature Publishing Group UK London, v. 8, n. 1, p. 59, 2022. Citado na página 4.

CHOUDHURY, A. R. et al. Segmentation of brain tumors using deeplabv3+. In: SPRINGER. *Brainlesion: Glioma, Multiple Sclerosis, Stroke and Traumatic Brain Injuries: 4th International Workshop, BrainLes 2018, Held in Conjunction with MICCAI 2018, Granada, Spain, September 16, 2018, Revised Selected Papers, Part II 4*. [S.l.], 2019. p. 154–167. Citado 2 vezes nas páginas 5 e 7.

DONG, S.; WANG, P.; ABBAS, K. A survey on deep learning and its applications. *Computer Science Review*, Elsevier, v. 40, p. 100379, 2021. Citado na página 4.

GIBBONS, E. et al. Clinical evaluation of deep learning and atlas-based auto-segmentation for critical organs at risk in radiation therapy. *Journal of Medical Radiation Sciences*, Wiley Online Library, v. 70, p. 15–25, 2023. Citado na página 1.

HIOKI, G. et al. Estudo comparativo de técnicas de detecção de mudanças em imagens de satélite em ambientes florestais. 2021. Citado na página 5.

- JANIESCH, C.; ZSCHECH, P.; HEINRICH, K. Machine learning and deep learning. *Electronic Markets*, Springer, v. 31, n. 3, p. 685–695, 2021. Citado na página 4.
- KUROKI, H.; NAGAI, T. Conjoined nerve root in a patient with lumbar disc herniation accompanied by a lumbosacral spine anomaly: a case report. *Journal of Medical Case Reports*, Springer, v. 17, n. 1, p. 82, 2023. Citado na página 2.
- MUSHTAQ, M. et al. Localization and edge-based segmentation of lumbar spine vertebrae to identify the deformities using deep learning models. *Sensors*, MDPI, v. 22, n. 4, p. 1547, 2022. Citado 2 vezes nas páginas 6 e 7.
- PENG, H. et al. Semantic segmentation of litchi branches using deeplabv3+ model. *IEEE Access*, v. 8, p. 164546–164555, 2020. Citado na página 5.
- QADRI, S. F. et al. Ct-based automatic spine segmentation using patch-based deep learning. *International Journal of Intelligent Systems*, Hindawi Limited, v. 2023, p. 1–14, 2023. Citado 2 vezes nas páginas 6 e 7.
- SHOUSHTARI, F. K.; SINA, S.; DEHKORDI, A. N. Automatic segmentation of glioblastoma multiform brain tumor in mri images: Using deeplabv3+ with pre-trained resnet18 weights. *Physica Medica*, Elsevier, v. 100, p. 51–63, 2022. Citado 2 vezes nas páginas 6 e 7.
- WANG, J.; LIU, X. Medical image recognition and segmentation of pathological slices of gastric cancer based on deeplab v3+ neural network. *Computer Methods and Programs in Biomedicine*, Elsevier, v. 207, p. 106210, 2021. Citado 2 vezes nas páginas 5 e 7.
- WANG, Y. et al. Automatic detection and recognition of nasopharynx gross tumour volume (gtvnx) by deep learning for nasopharyngeal cancer radiotherapy through magnetic resonance imaging. *Radiation Oncology*, Springer, v. 18, n. 1, p. 76, 2023. Citado na página 2.
- WANGENHEIM, V. *Avaliando, validando e testando o seu modelo: Metodologias de avaliação de performance*. 2022. <https://lapix.ufsc.br/ensino/reconhecimento-de-padroes/avaliando-validando-e-testando-o-seu-modelo-metodologias-de-avaliacao-de-performance/#Links_Interessantes>. Acessado em 15 de julho de 2024. Citado na página 8.
- XIE, X. et al. Oriented r-cnn for object detection. In: *Proceedings of the IEEE/CVF international conference on computer vision*. [S.l.: s.n.], 2021. p. 3520–3529. Citado na página 4.
- YAQUB, M. et al. Deeplabv3, ibco-based alcresnet: A fully automated classification, and grading system for brain tumor. *Alexandria Engineering Journal*, Elsevier, v. 76, p. 609–627, 2023. Citado na página 2.
- ZANZA, C. et al. Cervical spine injury: Clinical and medico-legal overview. *La radiologia medica*, Springer, v. 128, n. 1, p. 103–112, 2023. Citado na página 3.
- ZHOU, Z.-H. *Machine learning*. [S.l.]: Springer nature, 2021. Citado na página 3.
- ZHU, S. et al. A novel approach for apple leaf disease image segmentation in complex scenes based on two-stage deeplabv3+ with adaptive loss. *Computers and Electronics in Agriculture*, Elsevier, v. 204, p. 107539, 2023. Citado na página 5.

Avaliação Final de TCC 01

ESTE DOCUMENTO DEVE SER PREENCHIDO PELO PROFESSOR AVALIADOR.

Este formulário será entregue junto com o pré-projeto impresso. Tal avaliação mais detalhada ajudará o aluno a evoluir seu trabalho futuro.

Professor, favor preencher antes da defesa apenas os nomes e a tabela de Avaliação Sobre o Documento.

Marque com um X a opção que melhor corresponde à sua avaliação.

Avaliação Sobre o Documento:

PARTE AVALIADA	RUIM	BOM	ÓTIMO
RESUMO			
INTRODUÇÃO			
OBJETIVOS			
REFERENCIAL TEÓRICO			
TRABALHOS RELACIONADOS			
PROPOSTA			
AVALIAÇÃO			
CRONOGRAMA			
ESCRITA EM GERAL			

Avaliação Sobre a Apresentação:

PARTE AVALIADA	RUIM	BOM	ÓTIMO
SEGURANÇA			
CLAREZA DE ARGUMENTAÇÃO			
TEMPO DE APRESENTAÇÃO			
SLIDES			

Nota :