

Segmentação da escoliose com DeepLabV3+

Hector J. R. Salgueiros

¹Sistemas de informação – Universidade Federal do Piauí (UFPI)
Picos, PI – Brazil

hectorsalg@ufpi.edu.br

Abstract. This paper presents a scoliosis image segmentation approach using the DeepLabV3+ architecture, evaluating the effects of pre-processing with the Contrast Limited Adaptive Histogram Equalization (CLAHE) technique. Tests were conducted with and without this pre-processing, comparing the results through quantitative metrics and qualitative observations. The results indicate that using CLAHE led to inferior segmentation performance.

Resumo. Este trabalho apresenta uma abordagem de segmentação de imagens de escoliose utilizando a arquitetura DeepLabV3+, avaliando os efeitos do uso de pré-processamento com a técnica CLAHE (Equalização Adaptativa do Histograma com Limitação de Contraste). Foram realizados testes com e sem esse pré-processamento, comparando os resultados obtidos a partir de métricas quantitativas e observações qualitativas. Os resultados indicam que o CLAHE obteve um resultado inferior para uma segmentação.

1. Introdução

A segmentação de imagens é uma etapa fundamental em sistemas de análise de imagens médicas, permitindo isolar regiões de interesse para diagnóstico e tratamento. No contexto da escoliose, a detecção precisa da curvatura da coluna, que é essencial para acompanhamento clínico. Redes neurais convolucionais, como o DeepLabV3+, têm-se mostrado eficazes em tarefas de segmentação semântica [Li et al. 2023]. Este trabalho investiga o impacto do aprendizado do modelo com e sem o pré-processamento CLAHE.

2. Metodologia

A metodologia adotada compreendeu as seguintes etapas:

- **Base de dados:** Utilizamos um conjunto de imagens radiográficas da coluna vertebral rotuladas manualmente para segmentação, disponível pelo Roboflow.
- **Split de treino:** 80% treino, 10% validação, 10% teste.
- **Pré-processamento:** Foram realizados dois experimentos: (i) com aplicação do CLAHE para realce de contraste, e (ii) sem aplicação de pré-processamento.
- **Modelo:** Utilizou-se a arquitetura DeepLabV3+ com backbone ResNet-50, treinada por 50 épocas com função de perda Dice Loss e otimizador Adam.
- **Hiperparâmetros:** Batch size 8, Learning rate 0,001.
- **Avaliação:** As segmentações foram avaliadas usando métricas de IoU (Intersection over Union), Dice, Precision, Recall, F1-Score e Pixel Accuracy.

3. Resultados Alcançados

Os resultados obtidos nos testes com e sem CLAHE estão resumidos na Tabela 1 e Figuras 1 e 2. Pode-se observar uma perda significativa nas métricas quando o pré-processamento foi aplicado.

Tabela 1. Resultados comparativos entre os testes com e sem CLAHE

Métrica	Sem CLAHE	Com CLAHE
IoU	0,8765	0,6114
Dice	0,9302	0,6938
Precision	0,9080	0,8453
Recall	0,9553	0,6380
F1-Score	0,9302	0,6938
Pixel Accuracy	0,9905	0,9712

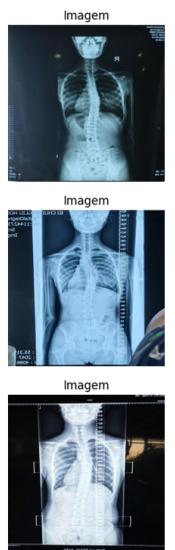


Figura 1. Modelo sem pré-processamento CLAHE.

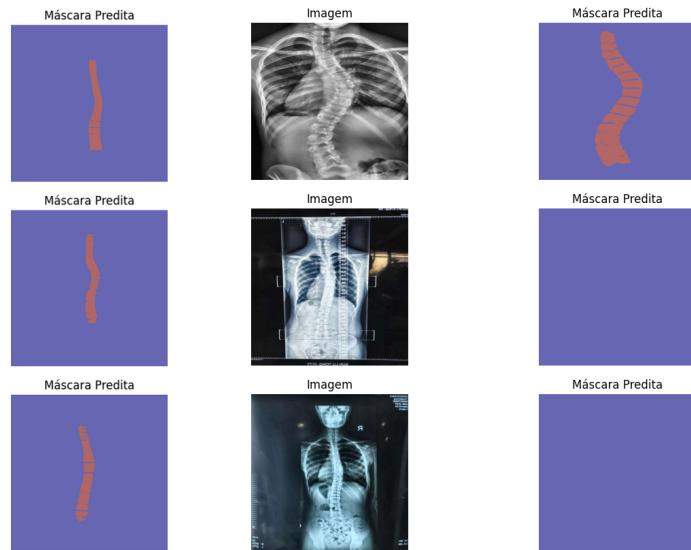


Figura 2. Modelo com pré-processamento CLAHE.

Conforme resultados, apesar do filtro CLAHE exibir visivelmente a estrutura óssea ao olho humano, como apresentados na Figura 1 e 2, o modelo apresentou melhores resultados sem a utilização do pré-processamento CLAHE.

4. Considerações finais

A aplicação do CLAHE como pré-processamento interferiu para a melhora da qualidade da segmentação em imagens radiográficas da coluna. As perdas observadas nas métricas e na inspeção visual sugerem que esse tipo de pré-processamento deve ser desconsiderado em pipelines de segmentação médica automatizada com o modelo DeepLabV3+. Trabalhos futuros podem explorar outras técnicas de realce e comparar com o CLAHE, bem como testar diferentes arquiteturas de redes neurais.

Referências

- Li, X., Li, Y., Ai, J., Shu, Z., Xia, J., et al. (2023). Semantic segmentation of uav remote sensing images based on edge feature fusing and multi-level upsampling integrated with deeplabv3+. *Plos one*, 18(1):e0279097.