

Trabalho 02 (SPN)

Hector José Rodrigues Salgueiros
Universidade Federal do Piauí
Sistemas de Informação
Picos, Brasil
hectorsalg@ufpi.edu.br

I. INTRODUÇÃO

A mobilidade inteligente representa um paradigma emergente na gestão de sistemas de transporte urbanos, integrando tecnologias avançadas de comunicação, computação e sensoriamento para criar ecossistemas de transporte mais eficientes, seguros e sustentáveis. Neste contexto, os veículos autônomos surgem como elementos centrais, capazes de coletar e processar dados em tempo real, comunicar-se com infraestruturas viárias e tomar decisões autônomas de navegação [1].

A complexidade inerente a estes sistemas distribuídos, caracterizada pela interdependência entre múltiplos componentes heterogêneos e requisitos rigorosos de qualidade de serviço, demanda ferramentas de modelagem e simulação capazes de capturar adequadamente seu comportamento dinâmico. As Redes de Petri Estocásticas (SPN) se apresentam como um formalismo matemático particularmente adequado para esta finalidade, permitindo a representação de concorrência, sincronização e compartilhamento de recursos de forma intuitiva e matematicamente fundamentada [2].

Este trabalho contribui para o estado da arte através de uma análise comparativa entre modelos absorventes e não-absorventes aplicados a sistemas de mobilidade inteligente, investigando o impacto do dimensionamento de infraestrutura computacional em métricas de desempenho críticas. A validação experimental foi realizada através do ambiente PASID-VALIDATOR, permitindo a avaliação de cenários realistas com diferentes configurações de capacidade computacional.

II. ARQUITETURA DO SISTEMA

A Figura 1 apresenta uma visão simplificada de um ecossistema de Veículos Autônomos e Mobilidade Inteligente, destacando os principais atores envolvidos na comunicação: os próprios veículos, as Unidades de Rua (RSUs) e a Cloud. Esta arquitetura hierárquica permite distribuir funcionalidades computacionais de acordo com seus requisitos de latência e processamento.

Nesta arquitetura, os Veículos Autônomos 1 e 2 representam os agentes inteligentes capazes de se locomover e coletar dados do ambiente através de sensores multimodais (LIDAR, câmeras, radar, GPS). Eles se comunicam entre si (V2V - Vehicle-to-Vehicle) e com as RSUs (V2I - Vehicle-to-Infrastructure), que são infraestruturas fixas instaladas ao longo das vias. As RSUs atuam como pontos de acesso locais, processando informações em tempo real para auxiliar na

navegação, no gerenciamento do tráfego e na segurança viária, realizando computação de borda para aplicações sensíveis a latência [3].

Por fim, a Cloud representa o centro de processamento de dados em grande escala. Para ela são enviadas informações consolidadas pelas RSUs e pelos veículos, permitindo análises macro, aprendizado de máquina, atualizações de software remotas e o gerenciamento de toda a frota de forma centralizada. Esta arquitetura combinada é fundamental para criar um sistema de transporte seguro e eficiente, permitindo o balanceamento ótimo entre processamento local e centralizado [4].

A. Tecnologias de Comunicação

O ecossistema de comunicação se apoia em tecnologias de comunicação veicular do tipo *Vehicle-to-Everything* (V2X), que incluem os padrões IEEE 802.11p (DSRC) e C-V2X (Celular V2X). Estes padrões garantem baixa latência (inferior a 10ms) e alta confiabilidade (acima de 99%), fundamentais para tomadas de decisão em tempo real por parte dos veículos autônomos [5]. A evolução para padrões 5G-NR V2X promete melhorias significativas em termos de capacidade, eficiência espectral e suporte a comunicações ultraconfiáveis de baixa latência (URLLC).

B. Aspectos de Segurança e Privacidade

Outro aspecto relevante é a segurança da comunicação. As RSUs e a Cloud devem empregar criptografia de ponta-a-ponta e autenticação distribuída para garantir a integridade e confidencialidade dos dados trocados. Estratégias baseadas em *blockchain* vêm sendo investigadas como mecanismos de confiança descentralizada, permitindo a criação de registros imutáveis de eventos críticos de segurança sem a necessidade de uma autoridade central [6]. Adicionalmente, técnicas de preservação de privacidade como k-anonimato e diferenciação são essenciais para proteger informações sensíveis dos usuários.




Fig. 1. Arquitetura de um sistema de comunicação para veículos autônomos e mobilidade inteligente, mostrando a interação entre veículos, RSUs e cloud.

III. MODELO NÃO-ABSORVENTE

A Figura 2 ilustra um modelo de processamento em camadas para as RSUs baseado em Redes de Petri Estocásticas. Este modelo demonstra o fluxo de dados desde a entrada até a saída, com integração à nuvem, representando um sistema em operação contínua.

O modelo não absorvente foi escolhido para representar sistemas em operação contínua, onde a entrada de novos eventos é constante e o sistema nunca chega a um estado terminal. Tal modelagem é adequada para sistemas veiculares, que funcionam de forma ininterrupta e reativa, processando fluxos contínuos de dados provenientes de sensores e comunicações.

A. Componentes do Modelo

O modelo é composto por vários estágios de processamento representados por transições temporizadas e lugares:

- **Entrada de Dados:** Representa a chegada de dados dos veículos e sensores, modelada como um processo de Poisson com taxa λ .
- **Fila de Processamento:** Armazena requisições aguardando processamento pelos recursos computacionais.
- **Contêineres de Processamento:** Representam os recursos computacionais disponíveis na RSU, com capacidade definida pelo número de tokens no lugar correspondente.
- **Integração com Cloud:** Modela a comunicação com a cloud para processamento não crítico em termos de tempo.
- **Saída:** Gera resultados acionáveis como comandos para veículos ou atualizações de sinalização.

As transições temporizadas são caracterizadas por distribuições exponenciais que modelam tempos de processamento e comunicação, permitindo a análise analítica das métricas de desempenho através da teoria de processos estocásticos de Markov.




Fig. 2. Modelo não absorvente de processamento de dados em containers para uma RSU integrada à cloud.

B. Análise de Desempenho

Para o modelo não absorvente, as principais métricas de interesse incluem:

$$U = \frac{\lambda}{\mu \cdot N} \quad (\text{Utilização para sistemas M/M/N}) \quad (1)$$

$$T = \lambda \cdot (1 - P_{drop}) \quad (\text{Throughput efetivo}) \quad (2)$$

$$MRT = \frac{1}{\mu - \lambda} \quad (\text{Tempo médio de resposta para M/M/1}) \quad (3)$$

onde λ é a taxa de chegada, μ é a taxa de serviço, N é o número de servidores e P_{drop} é a probabilidade de perda de pacotes.

IV. METODOLOGIA DE SIMULAÇÃO

Nesta seção são apresentados os cenários avaliados neste modelo. O cenário apresenta variações na quantidade de núcleos da Cloud, representando diferentes níveis de capacidade de processamento. As simulações foram realizadas no ambiente PASID-VALIDATOR, que permite a modelagem SPN e a análise de métricas de desempenho sob carga variável.

A. Configuração Experimental

As simulações foram conduzidas com os seguintes parâmetros:

- Taxa de chegada de requisições (λ): 100/segundo
- Taxa de serviço por núcleo (μ): 20 requisições/segundo
- Número de núcleos: 32, 48 e 64

O intervalo de confiança de 95

B. Cenário 1: Variação de Núcleos de Processamento

Neste cenário será avaliado o desempenho com diferentes quantidades de núcleos. A quantidade de núcleos está configurada para 32, 48 e 64 núcleos, a fim de observar o comportamento do sistema sob variação de paralelismo.

A Figura 3 apresenta a utilização da Cloud. A Figura 4 apresenta o MRT (Mean Response Time). A Figura 5 apresenta a taxa de transferência do sistema. A Figura 6 apresenta o *drop* da Cloud. Essas figuras apresentam resultados obtidos através do modelo não absorvente.

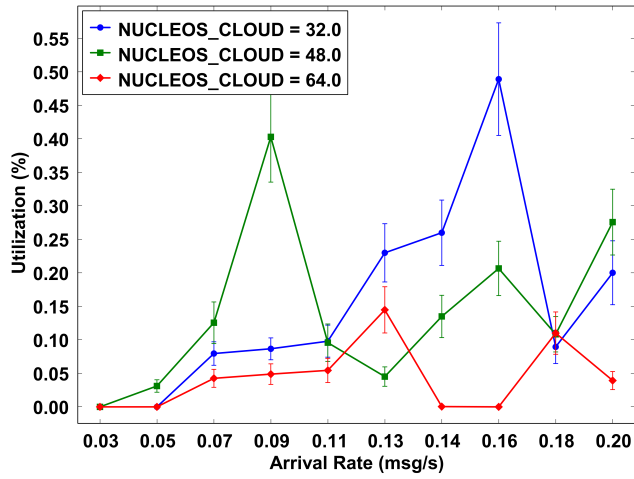


Fig. 3. Utilização da Cloud com 32, 48 e 64 núcleos. Observa-se redução na utilização à medida que aumenta a capacidade computacional.




Fig. 5. Throughput com 32, 48 e 64 núcleos. A capacidade de processamento aumenta proporcionalmente com o número de núcleos.

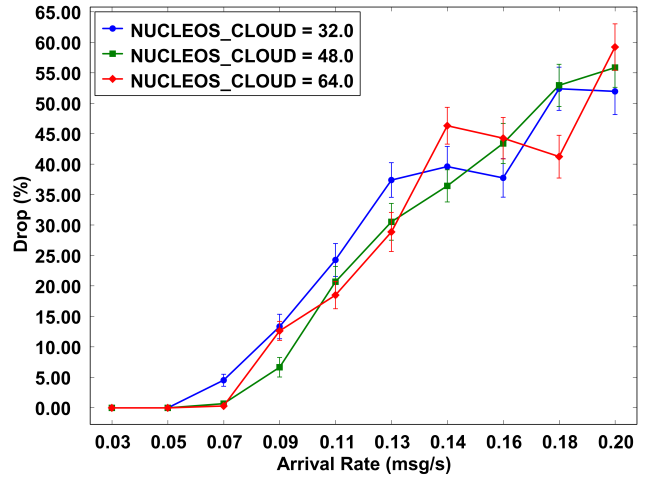


Fig. 6. Drop da Cloud com 32, 48 e 64 núcleos. A probabilidade de perda de pacotes reduz drasticamente com maior capacidade.




Fig. 4. MRT com 32, 48 e 64 núcleos. O tempo de resposta reduz significativamente com o aumento de núcleos, especialmente sob alta carga.

V. MODELO ABSORVENTE

A Figura 7 ilustra um modelo de processamento em camadas para as RSUs utilizando uma abordagem absorvente. Este modelo demonstra o fluxo de dados desde a entrada até a saída, com integração à nuvem, mas com a característica de eventualmente atingir um estado terminal.

O modelo absorvente representa uma condição em que o sistema atinge um estado terminal, ou seja, quando todas as tarefas são processadas e o sistema não recebe novas entradas. Este tipo de modelagem é útil para simular situações de desligamento, manutenção ou falhas críticas, permitindo analisar o tempo necessário para esvaziar o sistema (MTTA - Mean Time To Absorption) [7].




Fig. 7. Modelo absorvente de processamento de dados em containers para uma RSU integrada à cloud.

A. Análise do MTTA

A Figura 8 apresenta o MTTA do sistema para diferentes configurações iniciais. O MTTA representa o tempo esperado para que o sistema atinja um estado absorvente, onde todas as requisições foram processadas e não há novas chegadas.

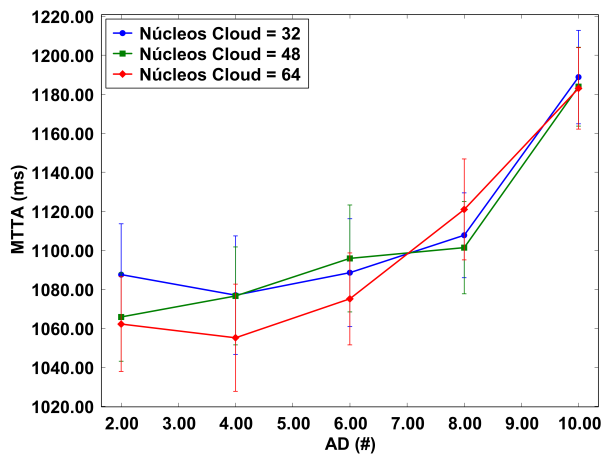


Fig. 8. Gráfico do MTTA obtido através do modelo absorvente. O tempo para absorção aumenta com a carga inicial do sistema.

Esta métrica é particularmente relevante para planejamento de manutenção e procedimentos de desligamento controlado, onde é necessário estimar o tempo requerido para processar toda a carga remanescente antes de interromper o sistema.

VI. ANÁLISE DO CDF

A Figura 9 apresenta a Função de Distribuição Cumulativa (CDF) do sistema, que permite observar a distribuição acumulada dos tempos de resposta. Esta análise é fundamental para compreender as características de latência do sistema sob diferentes condições de carga.




Fig. 9. Gráfico do CDF obtido através do modelo não absorvente, mostrando a distribuição dos tempos de resposta.

A análise do CDF é útil para compreender o comportamento probabilístico do sistema. Uma curva mais inclinada indica maior previsibilidade e estabilidade, enquanto curvas mais suaves indicam variabilidade nos tempos de resposta.

Estas observações reforçam a importância de um provisionamento adequado de recursos para garantir qualidade de serviço consistente, particularmente para aplicações de segurança que requerem tempos de resposta máximos garantidos.

VII. DISCUSSÃO E TRABALHOS FUTUROS

Os resultados apresentados demonstram claramente o impacto do dimensionamento de infraestrutura nas métricas de desempenho de sistemas de mobilidade inteligente. A abordagem baseada em SPN mostrou-se interessante para modelar a complexidade destes sistemas e prever seu comportamento sob diferentes condições operacionais.

Como trabalhos futuros, planeja-se:

- Estender o modelo para incluir mobilidade veicular explícita, considerando handover entre RSUs
- Incorporar modelos de consumo energético para avaliar eficiência energética

VIII. CONCLUSÃO

Este trabalho apresentou uma análise abrangente de sistemas de mobilidade inteligente através de modelagem com Redes de Petri Estocásticas. Foram investigados tanto modelos absorventes quanto não-absorventes, permitindo uma caracterização completa do comportamento do sistema sob diferentes perspectivas.

Os resultados demonstraram que o dimensionamento adequado de infraestrutura computacional é crítico para garantir qualidade de serviço em aplicações de mobilidade inteligente. Especificamente, foi observado que:

- O aumento de capacidade computacional reduz tempos de resposta e probabilidade de perda de pacotes
- A análise do CDF revela maior previsibilidade temporal em configurações com maior capacidade

- O MTTA fornece insights valiosos para planejamento de manutenção e procedimentos de desligamento

Estes achados fornecem diretrizes valiosas para arquitetos de sistema e gestores de infraestrutura de transporte inteligente, contribuindo para o desenvolvimento de cidades mais inteligentes, seguras e eficientes.

REFERENCES

- [1] S. Shaheen and A. Cohen, "Mobility on demand (mod) and mobility as a service (maas): Early understanding of the impacts," *Transportation Research Board*, vol. 2672, no. 5, pp. 1–9, 2018.
- [2] G. Balbo, "Introduction to stochastic petri nets," *Lectures on Formal Methods and Performance Analysis*, pp. 84–155, 2001.
- [3] J. Contreras, S. Zeadally, and J. I. Guerrero, "Mobile edge computing for connected vehicles," *IEEE Network*, vol. 32, no. 4, pp. 14–21, 2018.
- [4] Y. Sun, J. Zhang, and J. Liu, "Cloud-edge coordination in intelligent transportation systems: A survey," *IEEE Transactions on Intelligent Transportation Systems*, vol. 23, no. 6, pp. 5124–5142, 2022.
- [5] K. Abboud, H. A. Omar, and W. Zhuang, "Interworking of dsrc and cellular network technologies for v2x communications: A survey," *IEEE Transactions on Vehicular Technology*, vol. 65, no. 12, pp. 9457–9470, 2016.
- [6] A. Lei, H. Cruickshank, Y. Cao, P. Asuquo, C. P. A. Ogah, and Z. Sun, "Blockchain-based dynamic key management for heterogeneous intelligent transportation systems," *IEEE Internet of Things Journal*, vol. 4, no. 6, pp. 1832–1843, 2019.
- [7] M. A. Marsan, G. Conte, and G. Balbo, "A class of generalized stochastic petri nets for the performance evaluation of multiprocessor systems," *ACM Transactions on Computer Systems*, vol. 2, no. 2, pp. 93–122, 1984.