

# VEÍCULOS AUTÔNOMOS E MOBILIDADE INTELIGENTE

Hector José Rodrigues Salgueiros

*Universidade Federal do Piauí*

*Sistemas de Informação*

Picos, Brasil

hectorsalg@ufpi.edu.br

**Abstract**—A mobilidade inteligente representa um avanço significativo na integração entre veículos autônomos, infraestrutura viária e computação distribuída, visando maior eficiência, segurança e sustentabilidade no transporte urbano. Este trabalho apresenta uma análise comparativa entre modelos absorventes e não-absorventes baseados em Redes de Petri Estocásticas (SPN), aplicados a sistemas de mobilidade inteligente. Utilizando o ambiente PASID-VALIDATOR, foram simulados diferentes cenários com variação na capacidade computacional da nuvem (4, 8 e 16 núcleos), avaliando métricas de desempenho como utilização, tempo médio de resposta (MRT), throughput e probabilidade de perda de pacotes. Os resultados indicam que o aumento da capacidade de processamento reduz significativamente o tempo de resposta e as perdas, além de aumentar a previsibilidade e estabilidade do sistema. O modelo absorvente, por sua vez, permite estimar o MTTA (Mean Time To Absorption), útil para planejamento de manutenção e desligamento controlado. Conclui-se que o dimensionamento adequado da infraestrutura é fundamental para assegurar qualidade de serviço e confiabilidade em ecossistemas de mobilidade inteligente.

**Palavras-chaves:** Veículos autônomos, mobilidade inteligente, redes de Petri estocásticas, PASID-VALIDATOR, desempenho de sistemas distribuídos..

## I. INTRODUÇÃO

A mobilidade inteligente representa um paradigma emergente na gestão de sistemas de transporte urbanos, integrando tecnologias avançadas de comunicação, computação e sensoriamento para criar ecossistemas de transporte mais eficientes, seguros e sustentáveis. Neste contexto, os veículos autônomos surgem como elementos centrais, capazes de coletar e processar dados em tempo real, comunicar-se com infraestruturas viárias e tomar decisões autônomas de navegação [1].

A complexidade inerente a estes sistemas distribuídos, caracterizada pela interdependência entre múltiplos componentes heterogêneos e requisitos rigorosos de qualidade de serviço, demanda ferramentas de modelagem e simulação capazes de capturar adequadamente seu comportamento dinâmico. As Redes de Petri Estocásticas (SPN) se apresentam como um formalismo matemático particularmente adequado para esta finalidade, permitindo a representação de concorrência, sincronização e compartilhamento de recursos de forma intuitiva e matematicamente fundamentada [2].

Este trabalho contribui para o estado da arte através de uma análise comparativa entre modelos absorventes e não-

absorventes aplicados a sistemas de mobilidade inteligente, investigando o impacto do dimensionamento de infraestrutura computacional em métricas de desempenho críticas. A validação experimental foi realizada através do ambiente PASID-VALIDATOR, permitindo a avaliação de cenários realistas com diferentes configurações de capacidade computacional.

## II. ARQUITETURA DO SISTEMA

A Figura 1 apresenta uma visão simplificada de um ecossistema de Veículos Autônomos e Mobilidade Inteligente, destacando os principais atores envolvidos na comunicação: os próprios veículos, as Unidades de Rua (RSUs) e a Cloud. Esta arquitetura hierárquica permite distribuir funcionalidades computacionais de acordo com seus requisitos de latência e processamento.

Nesta arquitetura, os Veículos Autônomos 1 e 2 representam os agentes inteligentes capazes de se locomover e coletar dados do ambiente através de sensores multimodais (LIDAR, câmeras, radar, GPS). Eles se comunicam entre si (V2V - Vehicle-to-Vehicle) e com as RSUs (V2I - Vehicle-to-Infrastructure), que são infraestruturas fixas instaladas ao longo das vias. As RSUs atuam como pontos de acesso locais, processando informações em tempo real para auxiliar na navegação, no gerenciamento do tráfego e na segurança viária, realizando computação de borda para aplicações sensíveis a latência [3].

Por fim, a Cloud representa o centro de processamento de dados em grande escala. Para ela são enviadas informações consolidadas pelas RSUs e pelos veículos, permitindo análises macro, aprendizado de máquina, atualizações de software remotas e o gerenciamento de toda a frota de forma centralizada. Esta arquitetura combinada é fundamental para criar um sistema de transporte seguro e eficiente, permitindo o balanceamento ótimo entre processamento local e centralizado [4].

### A. Tecnologias de Comunicação

O ecossistema de comunicação se apoia em tecnologias de comunicação veicular do tipo *Vehicle-to-Everything* (V2X), que incluem os padrões IEEE 802.11p (DSRC) e C-V2X (Celular V2X). Estes padrões garantem baixa latência (inferior

a 10ms) e alta confiabilidade (acima de 99%), fundamentais para tomadas de decisão em tempo real por parte dos veículos autônomos [5]. A evolução para padrões 5G-NR V2X promete melhorias significativas em termos de capacidade, eficiência espectral e suporte a comunicações ultraconfiáveis de baixa latência (URLLC).

### B. Aspectos de Segurança e Privacidade

Outro aspecto relevante é a segurança da comunicação. As RSUs e a Cloud devem empregar criptografia de ponta-a-ponta e autenticação distribuída para garantir a integridade e confidencialidade dos dados trocados. Estratégias baseadas em *blockchain* vêm sendo investigadas como mecanismos de confiança descentralizada, permitindo a criação de registros imutáveis de eventos críticos de segurança sem a necessidade de uma autoridade central [6]. Adicionalmente, técnicas de preservação de privacidade como k-anonimato e diferenciação são essenciais para proteger informações sensíveis dos usuários.

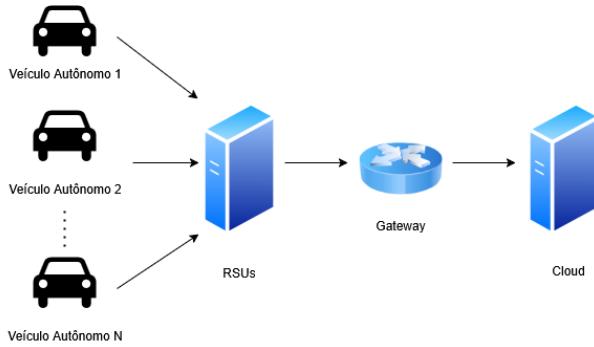


Fig. 1. Arquitetura de um sistema de comunicação para veículos autônomos e mobilidade inteligente, mostrando a interação entre veículos, RSUs e cloud.

### III. MODELO NÃO-ABSORVENTE

A Figura 2 ilustra um modelo de processamento em camadas para as RSUs baseado em Redes de Petri Estocásticas. Este modelo demonstra o fluxo de dados desde a entrada até a saída, com integração à nuvem, representando um sistema em operação contínua.

O modelo não absorvente foi escolhido para representar sistemas em operação contínua, onde a entrada de novos eventos é constante e o sistema nunca chega a um estado terminal. Tal modelagem é adequada para sistemas veiculares, que funcionam de forma ininterrupta e reativa, processando fluxos contínuos de dados provenientes de sensores e comunicações.

#### A. Componentes do Modelo

O modelo é composto por vários estágios de processamento representados por transições temporizadas e lugares:

- Entrada de Dados:** Representa a chegada de dados dos veículos e sensores, modelada como um processo de Poisson com taxa  $\lambda$ .
- Fila de Processamento:** Armazena requisições aguardando processamento pelos recursos computacionais.

- Contêineres de Processamento:** Representam os recursos computacionais disponíveis na RSU, com capacidade definida pelo número de tokens no lugar correspondente.
- Integração com Cloud:** Modela a comunicação com a cloud para processamento não crítico em termos de tempo.
- Saída:** Gera resultados acionáveis como comandos para veículos ou atualizações de sinalização.

As transições temporizadas são caracterizadas por distribuições exponenciais que modelam tempos de processamento e comunicação, permitindo a análise analítica das métricas de desempenho através da teoria de processos estocásticos de Markov.

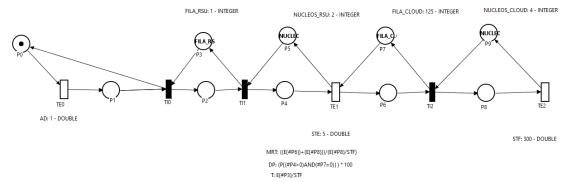


Fig. 2. Modelo não absorvente de processamento de dados em containers para uma RSU integrada à cloud.

#### B. Análise de Desempenho

Para o modelo não absorvente, as principais métricas de interesse incluem:

$$U = \frac{\lambda}{\mu \cdot N} \quad (\text{Utilização para sistemas M/M/N}) \quad (1)$$

$$T = \lambda \cdot (1 - P_{drop}) \quad (\text{Throughput efetivo}) \quad (2)$$

$$MRT = \frac{1}{\mu - \lambda} \quad (\text{Tempo médio de resposta para M/M/1}) \quad (3)$$

onde  $\lambda$  é a taxa de chegada,  $\mu$  é a taxa de serviço,  $N$  é o número de servidores e  $P_{drop}$  é a probabilidade de perda de pacotes.

### IV. METODOLOGIA DE SIMULAÇÃO

Nesta seção são apresentados os cenários avaliados neste modelo. O cenário apresenta variações na quantidade de núcleos da Cloud, representando diferentes níveis de capacidade de processamento. As simulações foram realizadas no ambiente PASID-VALIDATOR, que permite a modelagem SPN e a análise de métricas de desempenho sob carga variável.

#### A. Configuração Experimental

As simulações foram conduzidas com os seguintes parâmetros:

- Taxa de chegada de requisições ( $\lambda$ ): 100/segundo
- Taxa de serviço por núcleo ( $\mu$ ): 20 requisições/segundo
- Número de núcleos: 4, 8 e 16

O intervalo de confiança de 95% foi calculado para todas as métricas reportadas, garantindo significância estatística dos resultados.

### B. Cenário 1: Variação de Núcleos de Processamento

Neste cenário será avaliado o desempenho com diferentes quantidades de núcleos. A quantidade de núcleos está configurada para 4, 8 e 16 núcleos, a fim de observar o comportamento do sistema sob variação de paralelismo.

A Figura 3 apresenta a utilização da Cloud. A Figura 4 apresenta o MRT (Mean Response Time). A Figura 5 apresenta a taxa de transferência do sistema. A Figura 6 apresenta o *drop* da Cloud. Essas figuras apresentam resultados obtidos através do modelo não absorvente.

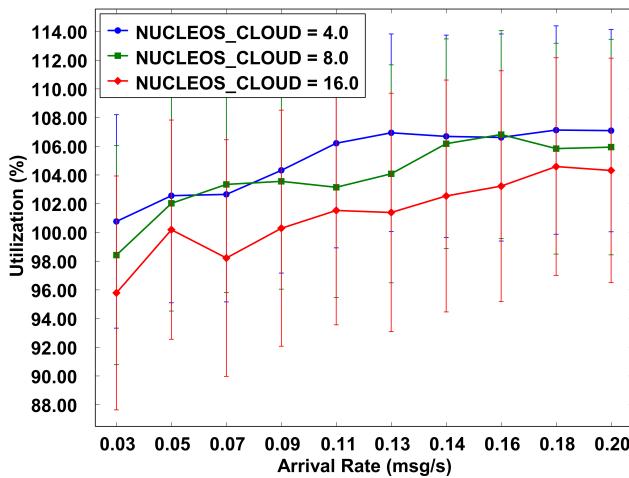


Fig. 3. Utilização da Cloud com 4, 8 e 16 núcleos. Observa-se redução na utilização à medida que aumenta a capacidade computacional.

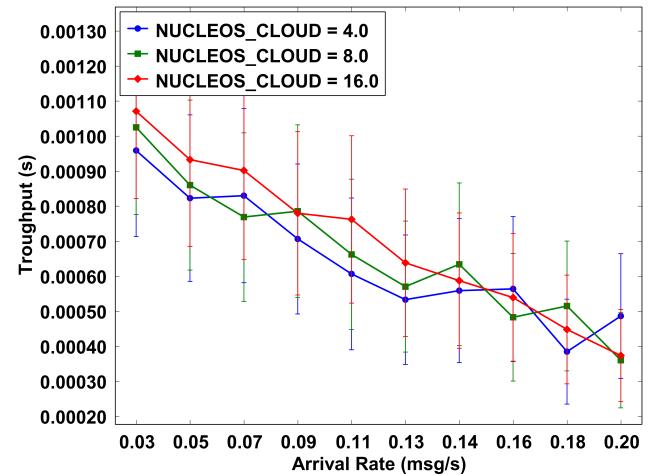


Fig. 5. Throughput com 4, 8 e 16 núcleos. A capacidade de processamento aumenta proporcionalmente com o número de núcleos.

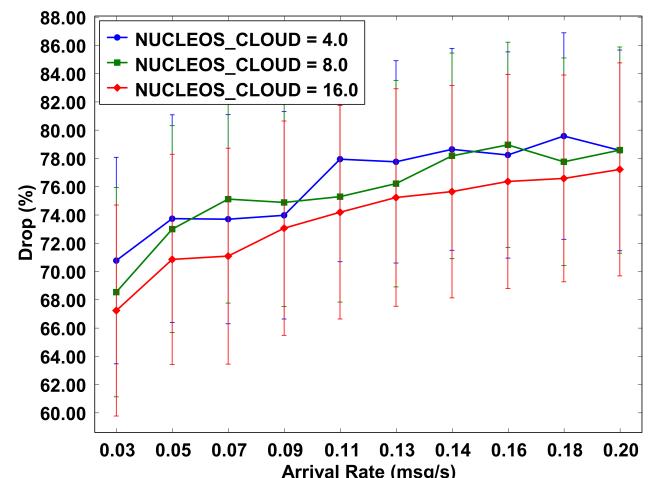


Fig. 6. Drop da Cloud com 4, 8 e 16 núcleos. A probabilidade de perda de pacotes reduz drasticamente com maior capacidade.

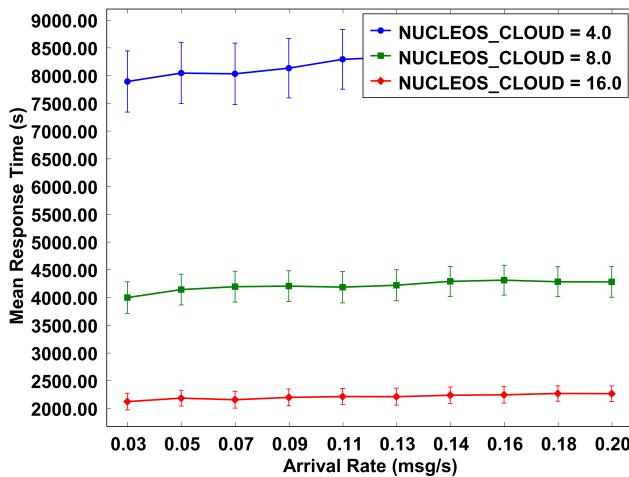


Fig. 4. MRT com 4, 8 e 16 núcleos. O tempo de resposta reduz significativamente com o aumento de núcleos, especialmente sob alta carga.

### C. Cenário 2: Tempo de serviço da camada Cloud

Neste cenário será avaliado o desempenho com diferentes tempos de serviço. A quantidade alterada foi do STF que está configurada para 300, 200 e 100, a fim de observar o comportamento do sistema sob variação de tempo.

A Figura 7 apresenta a utilização da Cloud. A Figura 8 apresenta o MRT (Mean Response Time). A Figura 9 apresenta a taxa de transferência do sistema. A Figura 10 apresenta o *drop* da Cloud. Essas figuras apresentam resultados obtidos através do modelo não absorvente.

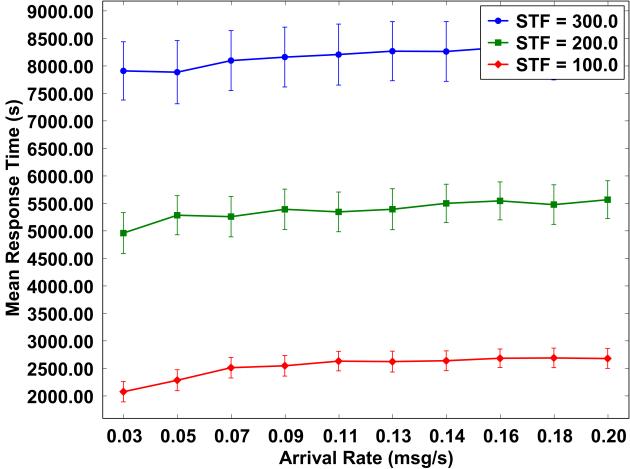


Fig. 7. Utilização com tempo de serviço da Cloud com 300, 200 e 100 no STF. Observa-se redução na utilização à medida que diminui o tempo de serviço.

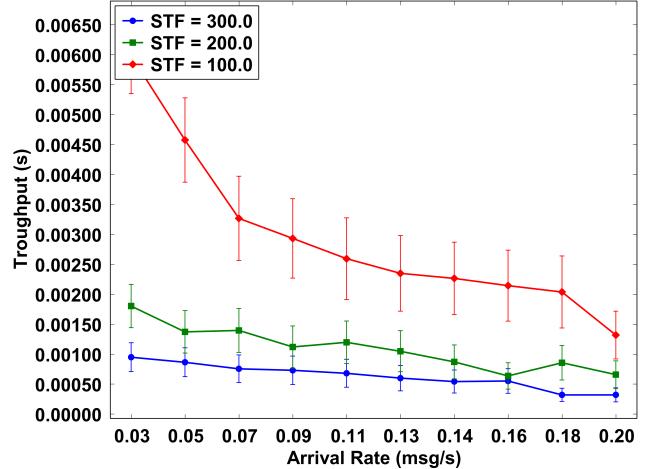


Fig. 9. Throughput com valores 300, 200 e 100 no STF.

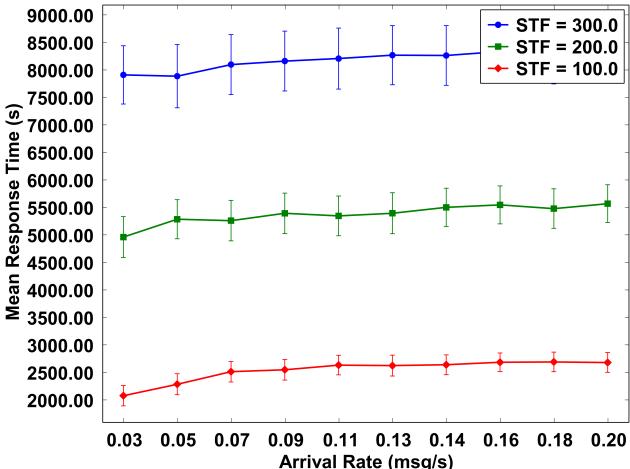


Fig. 8. MRT com tempo 300, 200 e 100. O tempo de resposta reduz significativamente com a redução do tempo de serviço.

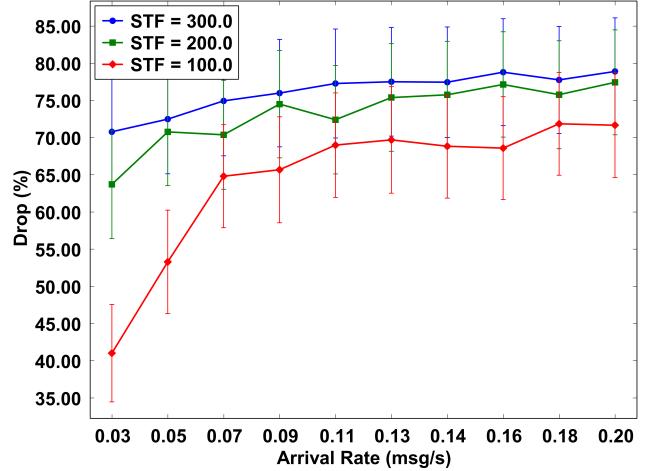


Fig. 10. Drop da Cloud com valores 300, 200 e 100 no STF. A probabilidade de perda de pacotes reduz drasticamente conforme o tempo de serviço diminui.

## V. MODELO ABSORVENTE

A Figura 11 ilustra um modelo de processamento em camadas para as RSUs utilizando uma abordagem absorvente. Este modelo demonstra o fluxo de dados desde a entrada até a saída, com integração à nuvem, mas com a característica de eventualmente atingir um estado terminal.

O modelo absorvente representa uma condição em que o sistema atinge um estado terminal, ou seja, quando todas as tarefas são processadas e o sistema não recebe novas entradas. Este tipo de modelagem é útil para simular situações de desligamento, manutenção ou falhas críticas, permitindo analisar o tempo necessário para esvaziar o sistema (MTTA - Mean Time To Absorption) [7].

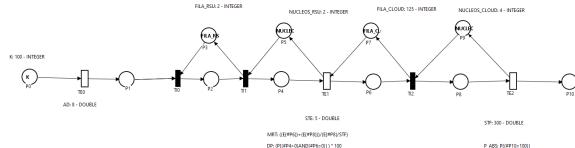


Fig. 11. Modelo absorvente de processamento de dados em containers para uma RSU integrada à cloud.

### A. Análise do MTTA

A Figura 12 apresenta o MTTA do sistema para diferentes configurações iniciais. O MTTA representa o tempo esperado para que o sistema atinja um estado absorvente, onde todas as requisições foram processadas e não há novas chegadas.

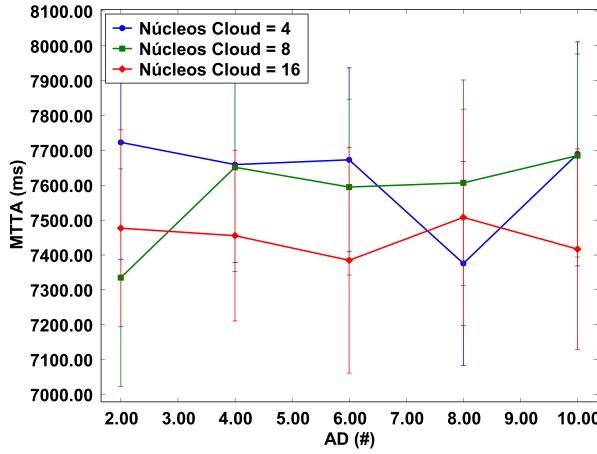


Fig. 12. Gráfico do MTTA obtido através do modelo absorvente. O tempo para absorção aumenta com a carga inicial do sistema.

Esta métrica é particularmente relevante para planejamento de manutenção e procedimentos de desligamento controlado, onde é necessário estimar o tempo requerido para processar toda a carga remanescente antes de interromper o sistema.

### VI. ANÁLISE DO CDF

A Figura 13 apresenta a Função de Distribuição Cumulativa (CDF) do sistema, que permite observar a distribuição acumulada dos tempos de resposta. Esta análise é fundamental para compreender as características de latência do sistema sob diferentes condições de carga.

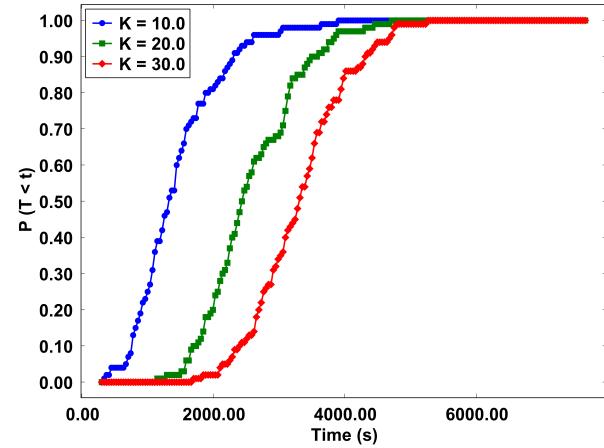


Fig. 13. Gráfico do CDF obtido através do modelo não absorvente, mostrando a distribuição dos tempos de resposta.

A análise do CDF é útil para compreender o comportamento probabilístico do sistema. Uma curva mais inclinada indica maior previsibilidade e estabilidade, enquanto curvas mais suaves indicam variabilidade nos tempos de resposta.

Estas observações reforçam a importância de um provisionamento adequado de recursos para garantir qualidade de serviço consistente, particularmente para aplicações de segurança que requerem tempos de resposta máximos garantidos.

### VII. DoE

A Tabela I apresenta os fatores e níveis utilizados neste trabalho, com tabmém apresentados na Figura 14.

Factor name	Low Setting	High Setting
CAPACITY_A	50.0	250.0
CAPACITY_B	50.0	250.0
CAPACITY_C	150.0	450.0
CAPACITY_D	2.0	6.0
STF	150.0	450.0

TABLE I  
FATORES E NÍVEIS DA SIMULAÇÃO

A Figura 14 ilustra um modelo de processamento em camadas para as RSUs utilizando uma abordagem absorvente. Este modelo demonstra o fluxo de dados desde a entrada até a saída, com integração à nuvem, mas com a característica de eventualmente atingir um estado terminal.

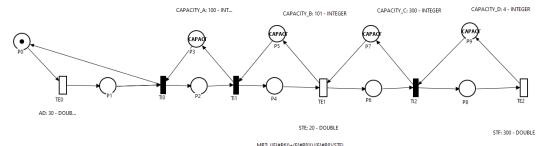


Fig. 14. Modelo não absorvente de processamento de dados em containers para uma RSU integrada à cloud para o DoE.

A Figura 15 apresenta a capacidade de interações de um componente do sistema com os demais. As Figuras 16, 17 e

18 apresentam interações entre Capacidade C e Capacidade D, Capacidade C e STF, Capacidade D e STF, respectivamente.

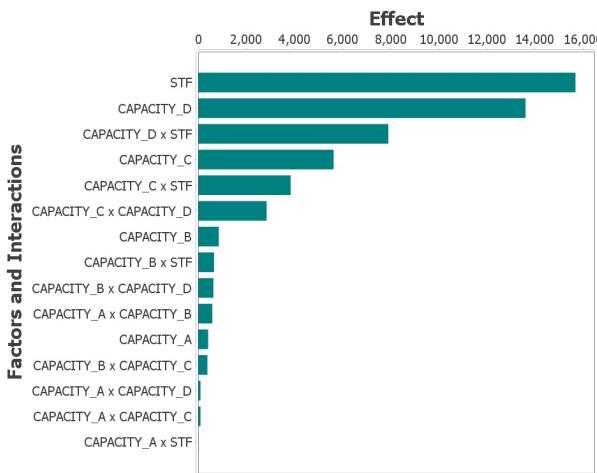


Fig. 15. Capacidade de interação de cada componente do sistema.

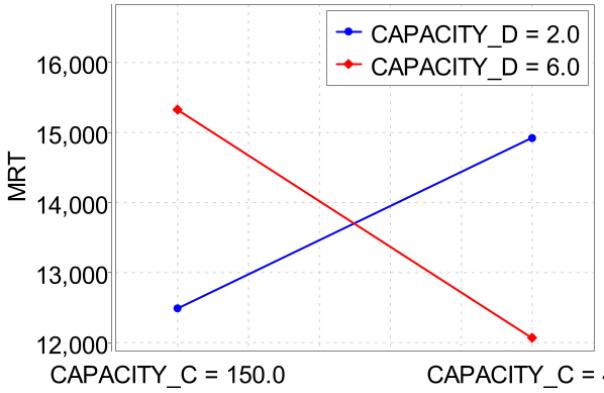


Fig. 16. Interação da Capacidade C e Capacidade D.

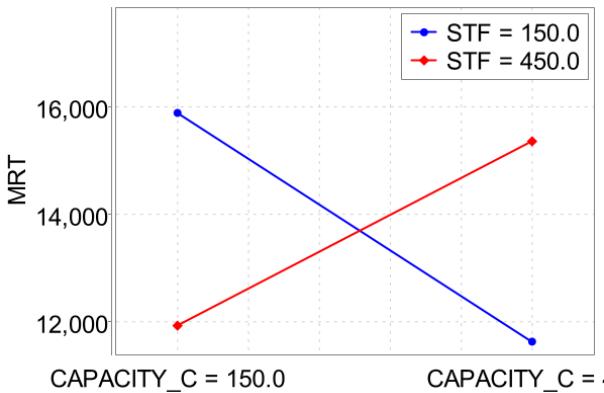


Fig. 17. Interação da Capacidade C e STF.

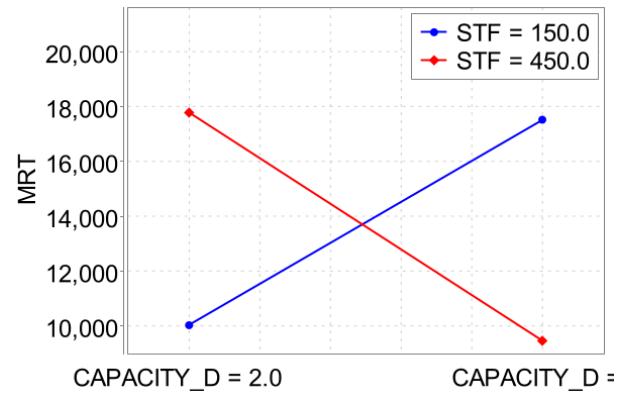


Fig. 18. Interação da Capacidade D e STF.

Gráficos onde o MRT se cruzam apresentam grande valor de interação entre eles.

A Tabela II apresenta as combinações

CAPACITY_A	CAPACITY_B	CAPACITY_C	CAPACITY_D	STF	MRT
50.000	50.000	150.000	2.000	150.000	7819.080
50.000	50.000	150.000	2.000	450.000	26282.510
50.000	50.000	150.000	6.000	150.000	2465.880
50.000	50.000	150.000	6.000	450.000	9151.120
50.000	50.000	450.000	2.000	150.000	10543.430
50.000	50.000	450.000	2.000	450.000	43418.850
50.000	50.000	450.000	6.000	150.000	3450.510
50.000	50.000	450.000	6.000	450.000	13583.740
50.000	250.000	150.000	2.000	150.000	7208.440
50.000	250.000	150.000	2.000	450.000	24038.090
50.000	250.000	150.000	6.000	150.000	2250.170
50.000	250.000	150.000	6.000	450.000	8126.790
50.000	250.000	450.000	2.000	150.000	10578.120
50.000	250.000	450.000	2.000	450.000	37085.400
50.000	250.000	450.000	6.000	150.000	3535.000
50.000	250.000	450.000	6.000	450.000	12836.6490
250.000	50.000	150.000	2.000	150.000	7619.050
250.000	50.000	150.000	2.000	450.000	24914.280
250.000	50.000	150.000	6.000	150.000	2558.720
250.000	50.000	150.000	6.000	450.000	8611.330
250.000	50.000	450.000	2.000	150.000	10609.420
250.000	50.000	450.000	2.000	450.000	39157.860
250.000	50.000	450.000	6.000	150.000	3172.500
250.000	50.000	450.000	6.000	450.000	13101.850
250.000	250.000	150.000	2.000	150.000	7382.810
250.000	250.000	150.000	2.000	450.000	23256.960
250.000	250.000	150.000	6.000	150.000	2377.380
250.000	250.000	150.000	6.000	450.000	8326.420
250.000	250.000	450.000	2.000	150.000	10209.590
250.000	250.000	450.000	2.000	450.000	40368.160
250.000	250.000	450.000	6.000	150.000	3259.930
250.000	250.000	450.000	6.000	450.000	12880.750

TABLE II  
COMBINAÇÕES DOS NÍVEIS E FATORES

## VIII. CONCLUSÃO

Este trabalho apresentou uma análise abrangente de sistemas de mobilidade inteligente através de modelagem com Redes de Petri Estocásticas. Foram investigados tanto modelos absorventes quanto não-absorventes, permitindo uma caracterização completa do comportamento do sistema sob diferentes perspectivas.

Os resultados demonstraram que o dimensionamento adequado de infraestrutura computacional é crítico para garantir

qualidade de serviço em aplicações de mobilidade inteligente. Especificamente, foi observado que:

- O aumento de capacidade computacional reduz tempos de resposta e probabilidade de perda de pacotes
- A redução do tempo de serviço reduz tempos de resposta e probabilidade de perda de pacotes
- A análise do CDF revela maior previsibilidade temporal em configurações com maior capacidade
- O MTTA fornece insights valiosos para planejamento de manutenção e procedimentos de desligamento

Estes achados fornecem diretrizes valiosas para arquitetos de sistema e gestores de infraestrutura de transporte inteligente, contribuindo para o desenvolvimento de cidades mais inteligentes, seguras e eficientes.

#### REFERENCES

- [1] S. Shaheen and A. Cohen, “Mobility on demand (mod) and mobility as a service (maas): Early understanding of the impacts,” *Transportation Research Board*, vol. 2672, no. 5, pp. 1–9, 2018.
- [2] G. Balbo, “Introduction to stochastic petri nets,” *Lectures on Formal Methods and Performance Analysis*, pp. 84–155, 2001.
- [3] J. Contreras, S. Zeadally, and J. I. Guerrero, “Mobile edge computing for connected vehicles,” *IEEE Network*, vol. 32, no. 4, pp. 14–21, 2018.
- [4] Y. Sun, J. Zhang, and J. Liu, “Cloud-edge coordination in intelligent transportation systems: A survey,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 23, no. 6, pp. 5124–5142, 2022.
- [5] K. Abboud, H. A. Omar, and W. Zhuang, “Interworking of dsrc and cellular network technologies for v2x communications: A survey,” *IEEE Transactions on Vehicular Technology*, vol. 65, no. 12, pp. 9457–9470, 2016.
- [6] A. Lei, H. Cruickshank, Y. Cao, P. Asuquo, C. P. A. Ogah, and Z. Sun, “Blockchain-based dynamic key management for heterogeneous intelligent transportation systems,” *IEEE Internet of Things Journal*, vol. 4, no. 6, pp. 1832–1843, 2019.
- [7] M. A. Marsan, G. Conte, and G. Balbo, “A class of generalized stochastic petri nets for the performance evaluation of multiprocessor systems,” *ACM Transactions on Computer Systems*, vol. 2, no. 2, pp. 93–122, 1984.